# PyTorch & Réseaux de Neurones Convolutifs

## Jour 3 — Après-midi

Julien Rolland

Formation M2 Développement Fullstack

Jour 3

# Plan du module


1. PyTorch
2. CNN
3. Training Loop

# Pourquoi passer à PyTorch ?

## Limite du « fait main » (J3-AM)

- Notre classe `Value` est **pédagogique** mais lente
- Python pur : quelques milliers d'opérations/s
- Un vrai réseau : **milliards** d'opérations par forward

## Même principe, autre échelle

Même graphe de calcul, même `backward()`
$\Rightarrow$ mais sur des **tenseurs** en C++/CUDA

## La solution industrielle

- **Calcul vectorisé** : matrices entières en une opération
- **Backend C++/CUDA** : parallélisme GPU
- **Écosystème riche** :
  - `torchvision` — Vision par ordinateur
  - `torchaudio` — Audio
  - `transformers` — NLP / LLM

# Le Concept de Tenseur (torch.Tensor)

$$\texttt{torch.Tensor} = \texttt{np.ndarray} + \textbf{autograd}$$

### np.ndarray

```python
import numpy as np

x = np.array([[1.0, 2.0],
              [3.0, 4.0]])
y = x ** 2
print(y.sum())  # 30.0
# Pas de gradient !
```

### torch.Tensor

```python
import torch

x = torch.tensor([[1.0, 2.0],
                  [3.0, 4.0]],
                 requires_grad=True)
y = x ** 2
y.sum().backward()
print(x.grad)  # 2*x
```

# NumPy ↔ PyTorch : Même API

## np.ndarray

```python
x.shape          # (3, 4)
x.dtype          # float64

np.ones((3, 4))
np.zeros((3, 4))
np.rand(3, 4)

x + y
x @ y            # produit matriciel
x.T              # transposee

x.reshape(2, 6)
x[0, :]          # slicing
```

## torch.Tensor

```python
x.shape          # torch.Size([3, 4])
x.dtype          # torch.float32

torch.ones(3, 4)
torch.zeros(3, 4)
torch.rand(3, 4)

x + y
x @ y            # produit matriciel
x.T              # transposee

x.reshape(2, 6)
x[0, :]          # slicing
```

# Nouveaux concepts : requires_grad et device

## requires_grad : suivi du calcul

- Marque un tenseur comme **variable à optimiser**
- PyTorch enregistre toutes les opérations le concernant
- `.backward()` remonte le graphe et calcule `.grad`

```python
x = torch.tensor([2.0], requires_grad=True)
y = x ** 3
y.backward()
print(x.grad)  # 3*x^2 = 12.0
```

## device : CPU ou GPU

- Les tenseurs vivent sur un **device**
- Les opérations exigent le **même device**
- `.to(device)` déplace un tenseur ou un modèle

```python
device = (
    "cuda" if torch.cuda.is_available()
    else "cpu"
)
x = x.to(device)
model = model.to(device)
```

# La Philosophie `torch.nn`

## Le `Module` : brique de base

- On ne gère **plus W** et ***b*** manuellement
- `nn.Linear`, `nn.Conv2d`... gèrent leurs paramètres
- `__init__` : définit les couches
- `forward()` : flux de données

## Avantage

`model.parameters()` retourne **tous** les poids ⇒ prêts pour l'optimiseur

```python
import torch.nn as nn
import torch.nn.functional as F

class MLP(nn.Module):
    def __init__(self, n_in, n_h, n_out):
        super().__init__()
        self.fc1 = nn.Linear(n_in, n_h)
        self.fc2 = nn.Linear(n_h, n_out)

    def forward(self, x):
        x = F.relu(self.fc1(x))
        return self.fc2(x)

model = MLP(784, 128, 10)
# Nombre de parametres :
n = sum(p.numel() for p in model.parameters())
print(f"{n} parametres")  # 101770
```

# Optimisation : `torch.optim`

## Plus de `w -= lr*grad` manuel

- **SGD** : descente de gradient classique
- **Adam** : adaptatif, converge rapidement
- **RMSprop** : stable pour les RNN

## Interface unifiée

Peu importe l'optimiseur, l'API est toujours la même : `opt.zero_grad()` / `opt.step()`

```python
import torch.optim as optim

# SGD classique
opt = optim.SGD(model.parameters(), lr=1e-2, momentum=0.9)

# Adam (defaut recommande)
opt = optim.Adam(model.parameters(), lr=1e-3)

# Meme interface pour tous :
opt.zero_grad()
loss.backward()
opt.step()
```

# Data : Dataset & DataLoader

## Dataset : accès aux données

- Définit **comment** accéder à un exemple
- Implémente `__len__` et `__getitem__`
- `torchvision.datasets` fournit MNIST, CIFAR...

## DataLoader : pipeline

- Gère le **batching** et le **shuffling**
- `num_workers` : chargement en parallèle
- Le GPU ne doit pas attendre le CPU

```python
from torch.utils.data import DataLoader
from torchvision import datasets, transforms

dataset = datasets.MNIST(
    root="data", train=True,
    transform=transforms.ToTensor(),
)

loader = DataLoader(
    dataset,
    batch_size=32,
    shuffle=True,
    num_workers=4,
)

for X, y in loader:
    # X.shape = [32, 1, 28, 28]
    pass
```

# La Training Loop Standard

## Les 5 étapes rituelles

1. `zero_grad()` : efface les anciens gradients
2. `model(x)` : forward pass
3. `criterion(out, y)` : calcul de la perte
4. `loss.backward()` : autograd
5. `optimizer.step()` : mise à jour des poids

## Piège classique

Oublier `zero_grad()` ⇒ gradients **accumulés** ⇒ divergence

```python
criterion = nn.CrossEntropyLoss()
optimizer = optim.Adam(model.parameters())

for epoch in range(n_epochs):
    for X, y in train_loader:
        # 1. Zero gradients
        optimizer.zero_grad()

        # 2. Forward pass
        output = model(X)

        # 3. Compute loss
        loss = criterion(output, y)

        # 4. Backward (autograd)
        loss.backward()

        # 5. Update weights
        optimizer.step()
```

# Pourquoi le MLP Échoue sur les Images ?

## Problème 1 : Explosion des paramètres

- Image $1024 \times 1024 \Rightarrow 10^6$ entrées
- Couche cachée de 512 neurones
- $10^6 \times 512 = \mathbf{5 \times 10^8}$ poids
- Rien que pour la **première couche** !

## Problème 2 : Perte de topologie

- Flatten $\Rightarrow$ perte de la **structure 2D**
- Un décalage d'1 pixel change tout le vecteur
- Le réseau ne voit pas la **proximité spatiale**

## Solution : CNN

- **Localité** : chaque neurone voit une petite zone
- **Partage des poids** : même filtre sur toute l'image
- **Hiérarchie** : bords $\rightarrow$ formes $\rightarrow$ objets

| | **MLP** | **CNN** |
|---|---|---|
| Params (1$^{re}$ couche) | 500M | $\sim$ 1K |
| Invariance translation | Non | Oui |
| Localité spatiale | Non | Oui |

# Architecture Globale d'un CNN

## Partie 1 : Extraction de features

- **Conv + ReLU + Pool** $\times N$
- Image $\rightarrow$ cartes de caractéristiques abstraites
- Taille spatiale $\downarrow$, profondeur (canaux) $\uparrow$

## Partie 2 : Classification

- **Flatten** : cartes $\rightarrow$ vecteur 1D
- MLP classique (J2) pour la décision finale
- Sortie : logits $\rightarrow$ softmax $\rightarrow$ classes

**MNIST : $[B, 1, 28, 28] \rightarrow [B, 10]$**

1 canal, $28 \times 28$ pixels, 10 classes

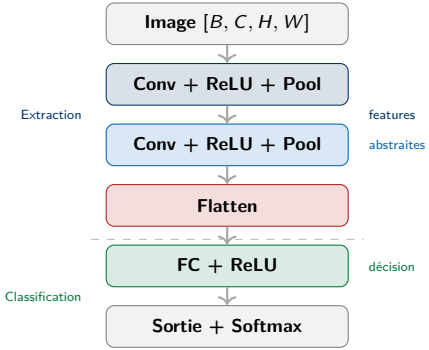

# La Convolution : Extraction de Features

## Le Kernel (Filtre)

- Petite fenêtre (ex: $3 \times 3$) qui **glisse** sur l'image
- **Localité** : chaque neurone ne voit qu'une zone
- **Partage des poids** : même filtre partout
- $\Rightarrow$ beaucoup moins de paramètres

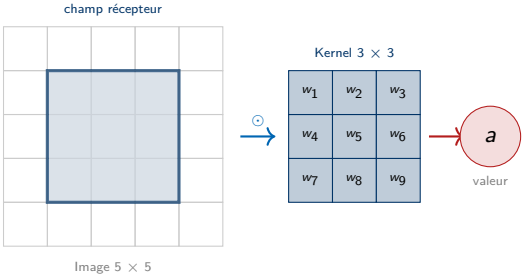


## Ce que le réseau apprend

Couche 1 : bords, contrastes
Couche 2 : coins, textures
Couche $n$ : visages, objets...

# Le Pooling : Réduction et Invariance

## Max Pooling $2 \times 2$

On garde la valeur **maximale** dans chaque zone $2 \times 2$

## Objectifs

1. **Réduire** la résolution spatiale (moins de calculs)
2. **Invariance** aux petites translations
3. **Élargir** le champ de vision des couches suivantes

## Résultat

Pool $2 \times 2$ : $H \times W \rightarrow \frac{H}{2} \times \frac{W}{2}$
$\Rightarrow 4\times$ moins de valeurs

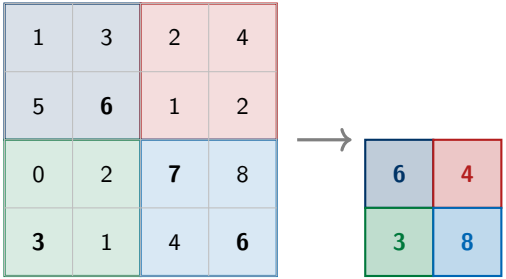


Feature map $4 \times 4$ Après pool $2 \times 2$

# Récapitulatif : De J3-AM à la Vision

## Concepts maîtrisés

- **Autograd** : graphe de calcul, chain rule, backward
- **Tenseurs** : généralisation vectorisée de `Value`
- **torch.nn** : couches, paramètres, forward
- **Convolutions** : localité, partage des poids
- **Pooling** : réduction, invariance
- **Training loop** : les 5 étapes rituelles

## Transition : MNIST $\rightarrow$ Vision complexe

- MNIST ($28 \times 28$, 10 classes) : CNN simple
- ImageNet ($224 \times 224$, 1000 classes) : ResNet, VGG
- Détection d'objets : YOLO, Faster R-CNN
- Segmentation : U-Net

## Demain : Séquences & Attention

De la vision spatiale aux données **séquentielles**
$\Rightarrow$ RNN, LSTM, Transformers