

Tokenisation & Word Embeddings

Jour 4 — Matin

Julien Rolland

Formation M2 Développement Fullstack

Jour 4

- 1 Du texte aux nombres
- 2 One-Hot vs embeddings denses
- 3 Word2Vec & propriétés
- 4 Visualisation & limites


Le défi du langage naturel

Le problème

- Image : grille de **pixels** = nombres réels $\in [0, 1]$
- Texte : suite de **symboles discrets**
- Comment calculer la « dérivée » d'un mot ?
- Comment gérer la **polysémie** ?

Objectif du matin

Construire un **pont** entre le monde discret (mots) et le monde continu (\mathbb{R}^d), afin que les réseaux de neurones puissent traiter du texte.



Niveau caractère

- + Petit vocabulaire (~ 256)
- + Aucun mot inconnu (OOV)
- Perte de la sémantique locale
- Séquences très longues

chat → [c, h, a, t]

Niveau mot (*word-level*)

- + Sens clair, séquences courtes
 - Vocabulaire immense ($V > 100\,000$)
 - Mots hors dictionnaire (OOV)
 - Flexions = tokens distincts
- « mangeras » \neq « mangeons »

Le dilemme

Caractère : trop fin — Mot : trop grossier ⇒ Y a-t-il un juste milieu ?

Principe du BPE

- ➊ Initialiser : chaque caractère est un token
- ➋ Compter les **paires** adjacentes les plus fréquentes
- ➌ Fusionner la paire la plus fréquente → nouveau token
- ➍ Répéter jusqu'à la taille de vocabulaire cible

Résultat

Mots **fréquents** conservés entiers.

Mots **rares** découpés en sous-mots significatifs.

Exemple

« inexplicablement »



[in | explicable | ment]

Vocabulaires modernes

- GPT-2 : 50 257 tokens (BPE)
- BERT : 30 522 tokens (WordPiece)
- Couvrent **n'importe quel** texte

Vectorisation naïve : *One-Hot Encoding*

v_{chat}
0
0
1
0
0
⋮

roi
reine
chat
chien
lune

Les 3 fléaux du One-Hot


- ① **Creusité** : $V = 50\,000$ valeurs, un seul 1
- ② **Orthogonalité** : $v_{\text{chat}} \cdot v_{\text{chien}} = 0$ — aucune notion de proximité sémantique
- ③ **Dimensionnalité** : taille vecteur = taille vocabulaire

La solution : embedding dense

Représenter chaque token par un vecteur **dense** de petite dimension $d \ll V$:

$$d \in \{64, 128, 256, 768, \dots\}$$

L'espace sémantique



Embedding dense $\in \mathbb{R}^d$

Chaque token est représenté par un vecteur réel :

$$\text{chat} \mapsto \begin{bmatrix} 0.31 \\ -0.87 \\ \vdots \end{bmatrix} \in \mathbb{R}^{768}$$

Intuition géométrique

Les **dimensions** encodent des traits latents : genre, animité, géographie, abstraction... .

Le sens devient une **position** dans l'espace : mots proches sémantiquement = proches géométriquement.

L'hypothèse distributionnelle


« On connaît un mot par ses voisins. »

« *le chat dort sur le tapis* »

⇒ « chat » cooccure avec : dormir, tapis, ...

Méthode Skip-gram

- ➊ Fenêtre glissante (taille k) sur le corpus
 - ➋ Réseau : prédire les mots **contexte** à partir du mot **cible**
 - ➌ Matrice de poids $\mathbf{W}_e \in \mathbb{R}^{V \times d}$ = dictionnaire d'embeddings
- * On jette la **prédiction** et ne conserve que \mathbf{W}_e



Propriété : analogies vectorielles

Les relations sémantiques = translations dans \mathbb{R}^d :


$$\vec{\text{roi}} - \vec{\text{homme}} + \vec{\text{femme}} \approx \vec{\text{reine}}$$

$$\vec{\text{Paris}} - \vec{\text{France}} + \vec{\text{Allemagne}} \approx \vec{\text{Berlin}}$$


Mesure de proximité : similarité cosinus

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} \in [-1, 1]$$

1 : synonymes 0 : sans rapport -1 : antonymes



Visualisation : réduction de dimension (t-SNE)



Le problème

Embeddings $\in \mathbb{R}^{768}$:
impossible à visualiser directement.

t-SNE / UMAP

- Projection en 2D
- **Préserve la structure locale** des voisinages
- Les clusters révèlent les **classes sémantiques**

Attention

t-SNE préserve la **proximité locale**, pas les distances globales.

Limites des embeddings statiques

Le problème : la polysémie

- « Je dépose de l'argent à la **banque**. »
- « Je pêche au bord de la **banque**. »


Dans Word2Vec / GloVe, « banque » possède **un seul vecteur**, mélangeant les deux sens.

Autres limites

- Ignorent l'ordre des mots
- Embeddings **figés** après entraînement
- Biais hérités des données d'entraînement

La solution : embeddings **contextuels**

Le vecteur d'un mot doit dépendre de son **contexte**.



J4-PM → mécanisme d'attention

L'attention permet de construire des embeddings **dynamiques** selon le contexte.