Crab Age Regression Challenge

Jour 5 — Après-midi

Julien Rolland

Formation M2 Développement Fullstack

Jour 5

Plan du module

1. Le défi
2. Règles et logistique
3. Stratégie
4. Évaluation

La Mission : Expertise en Aquaculture

Le problème terrain

Déterminer l'âge des crabes est essentiel pour la gestion durable des stocks, mais l'analyse en laboratoire (section des carapaces) est **longue et coûteuse**.

- Processus invasif, impossible à grande échelle
- Expertise humaine rare et coûteuse

L'objectif

Prédire l'**âge (en mois)** d'un crabe à partir de mesures physiques non-invasives.

Votre rôle

En tant qu'ingénieurs IA, livrer le modèle le plus précis possible pour **automatiser cette tâche** sur le terrain.

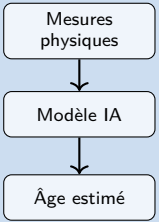

Le Dataset : Mesures de Crabes

Features

- **Sex :** Masculin (M), Féminin (F), Indéterminé (I)
- **Dimensions :** Longueur, Diamètre, Hauteur (mm)
- **Poids :** Total, sans coquille, viscères, carapace (g)

Target

Colonne **Age** — valeur continue (en mois).

Origine des données

Données synthétiques générées par IA.

Elles imitent les relations biologiques réelles tout en garantissant l'absence de solutions pré-existantes sur le web.

Attention

Variable catégorielle **Sex** à encoder.
Réfléchissez à la normalisation des poids.

La Métrique : Mean Absolute Error

Définition

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n} |\hat{y}_i - y_i|$$

C'est l'erreur moyenne en mois entre l'âge prédit et l'âge réel.

MAE vs MSE

- MSE pénalise **lourdement** les gros écarts (erreur quadratique)
- MAE est **robuste** aux outliers
- MAE est **directement interprétable** en unité métier

Traduction métier

« Mon modèle se trompe en moyenne de X mois sur l'âge du crabe. »

Objectif minimal

Battre la baseline de l'intervenant : le modèle « prédire la moyenne ».

Logistique Kaggle

Fichiers fournis

- **train.csv :** données d'entraînement avec la colonne Age
- **test.csv :** données sans étiquettes — vos prédictions ici
- **sample_submission.csv :** format attendu

Format de soumission

Un fichier CSV avec deux colonnes : `id` et `Age`.

Leaderboard : Public vs Private

- **Public (30%) :** visible immédiatement — votre score actuel
- **Private (70%) :** révélé au J6 — **c'est ce score qui compte**
- Attention à l'**overfitting** sur le leaderboard public !

Fin des soumissions

Matin du J6 à **09h00**.
Votre validation locale est votre meilleur guide.

Vos Leviers d'Action

Prétraitement & Feature Engineering

- Encoder **Sex** : one-hot ou ordinal ?
- Normaliser les features continues ?
- Créer des **ratios** biologiques :
  ex. Poids / Longueur, Poids / Volume
- Gérer les valeurs aberrantes

Choix du modèle

- **Baseline :** régression linéaire
- **Ensembles :** Random Forest, Gradient Boosting
- **Boosting :** XGBoost, LightGBM
- **MLP :** réseau de neurones simple

Validation locale

Créez votre propre split ou K-Fold.
Ne touchez au test set qu'en soumission.

Conseil

Le temps passé à comprendre vos données et créer des features pertinentes est souvent plus rentable que tester 50 algorithmes différents.

Évaluation & Notation (20 % du module)

Performance Technique — 10 points

- Rang final sur le **Private Leaderboard**
- Condition de validation : battre la baseline « prédire la moyenne »
- Classement relatif entre groupes

Soutenance Flash J6 — 10 points

5 minutes par groupe :

1. Pipeline de préparation des données
2. Modèles testés et choix final
3. **Vos échecs** : qu'est-ce qui n'a pas marché ?
4. Comment avez-vous lutté contre l'overfitting ?

Ce qui différencie les équipes

- Une vraie démarche expérimentale
- La rigueur de la validation locale
- La capacité à **expliquer** les choix

Critère clé de la soutenance

Les **échecs documentés** sont valorisés autant que les succès. L'ingénieur IA sait expliquer *pourquoi* une piste n'a pas fonctionné.

C'est parti !

Accès à la compétition

1. Connectez-vous sur **kaggle.com**
2. Rejoignez la compétition via le lien fourni
3. Téléchargez `train.csv` et `test.csv`
4. Première soumission : la baseline

Organisation suggérée

- **J5 PM :** EDA + baseline + feature engineering
- **J6 matin :** modèles avancés, tuning, soumission finale avant 09h00

Par où commencer ?

1. Charger les données, afficher `.describe()`
2. Encoder **Sex**, vérifier les NaN
3. Entraîner une **régression linéaire**
4. Soumettre — avoir un score de référence
5. Itérer : features, modèle, hyperparamètres

Bonne chance !

Vous avez tous les outils vus en cours — maintenant c'est à vous de jouer.