IA, Éthique & Société

Jour 6

Julien Rolland

Formation M2 Développement Fullstack

Jour 6

Plan du module

1. Pourquoi l'éthique en IA maintenant ?
2. Les biais
3. Fairness
4. RGPD & cadre légal
5. Responsabilité & gouvernance
6. Le problème de l'alignement
7. Votre rôle en tant que développeur

L'IA prend des décisions réelles

Ce n'est plus de la recherche

Des systèmes d'IA décident **aujourd'hui** :

- Si votre crédit est accordé
- Si votre CV est lu par un recruteur
- Quelle peine de prison recommander
- Quelle publicité vous montrer
- Si une tumeur est maligne

Une asymétrie de pouvoir

- La personne affectée ne sait souvent **pas qu'un algorithme** a décidé
- Elle ne peut ni **contester** ni **comprendre** la décision
- Les erreurs se **reproduisent à l'échelle** — pas une personne, des millions

La question centrale

Qui est responsable quand un algorithme se trompe — et que cette erreur coûte cher à quelqu'un ?

Trois cas qui ont marqué les esprits

COMPAS — Justice pénale (2016)

Algorithme prédit le risque de récidive aux États-Unis.

Étude ProPublica : les faux positifs (« va récidiver » alors que non) étaient **deux fois plus fréquents** pour les prévenus noirs que blancs.

Amazon Hiring (2018)

Outil de tri de CV entraîné sur les embauches des 10 années précédentes.

Résultat : pénalisait automatiquement les CV contenant le mot **« femmes »** (ex: « capitaine de l'équipe féminine »).

Arrêté en interne avant déploiement.

Google Translate — Genre (2017)

Traduction du turc (sans genre grammatical) vers l'anglais.

« O bir doktor » (il/elle est médecin) → **« He is a doctor »**

« O bir hemşire » (il/elle est infirmier/e) → **« She is a nurse »**

Le modèle reproduit les stéréotypes présents dans le corpus d'entraînement.

D'où vient un biais ?

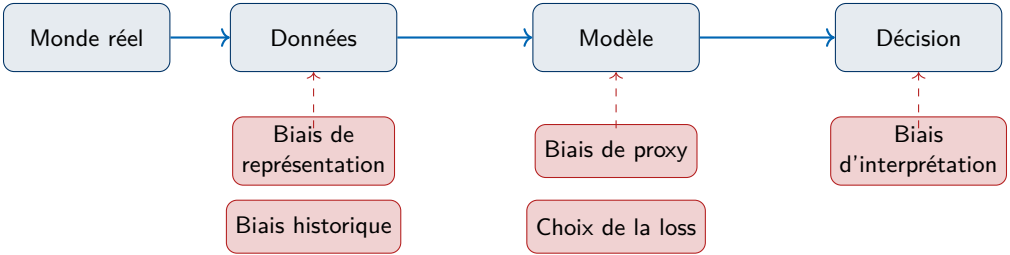

Idée clé

Un biais peut s'introduire **à chaque étape** du pipeline — même avec les meilleures intentions. Avoir un bon score de test ne garantit pas l'absence de biais.

Biais de représentation

Quand les données ne reflètent pas le monde

Si certaines populations sont **sous-représentées** dans le dataset, le modèle apprend moins bien pour elles — même si la performance globale semble bonne.

Exemples :

- Reconnaissance faciale entraînée sur des visages majoritairement blancs
- Textes sur internet sur-représentant certains groupes, langues, cultures

Mécanisme

Le modèle optimise pour minimiser l'erreur sur l'ensemble du dataset.

Les groupes majoritaires « pèsent » davantage dans la loss — le modèle leur donne implicitement la priorité.

Conséquence

Un modèle avec 95 % d'accuracy globale peut n'avoir que 70 % sur un sous-groupe minoritaire — sans que ça se voie dans la métrique globale.

Biais de représentation — exemple

MIT Gender Shades (Buolamwini & Gebru, 2018)

Audit de 3 systèmes de reconnaissance faciale commerciaux (Microsoft, IBM, Face++).

Taux d'erreur sur la classification du genre :

- Hommes à peau claire : **0,8 %**
- Femmes à peau sombre : **34,7 %**

Les datasets d'entraînement étaient composés majoritairement de visages masculins et à peau claire.

Pourquoi ce biais ?

Les datasets « standard » de l'époque (LFW, IJB-A) étaient constitués de photos de célébrités — majoritairement occidentales et masculines.

Le modèle n'avait jamais vu assez d'exemples de femmes à peau sombre pour apprendre leurs caractéristiques.

Impact

Cette étude a poussé Microsoft, IBM et Amazon à réviser leurs systèmes et à publier des engagements formels sur la diversité des données d'entraînement.

Biais historique

Apprendre du passé pour perpétuer ses inégalités

Si les données d'entraînement reflètent des **décisions passées inéquitables**, le modèle les reproduit — et les amplifie.

Exemples :

- Historique de crédits refusés à certains quartiers → le modèle refuse les candidats de ces quartiers
- Postes à responsabilité historiquement occupés par des hommes → le modèle favorise les profils masculins

La boucle de rétroaction

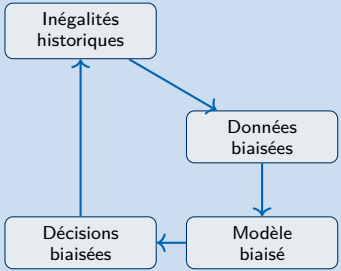

Le danger

Le modèle semble **objectif** car il s'appuie sur des données réelles. Mais il cristallise des inégalités qu'on pourrait vouloir corriger.

Biais historique — exemple

Amazon Hiring (2018)

Outil de tri de CV entraîné sur les embauches des 10 années précédentes.

Ces 10 ans reflétaient une industrie tech **largement dominée par des hommes**.

Résultat : le modèle pénalisait automatiquement les CV contenant le mot **« femmes »** (ex : « capitaine de l'équipe féminine ») et les diplômes d'universités féminines.

Arrêté en interne avant déploiement.

Les embeddings — pont avec J4

Vous avez vu que les embeddings capturent des relations sémantiques :

$$\texttt{roi} - \texttt{homme} + \texttt{femme} \approx \texttt{reine}$$

Le même mécanisme donne :

$$\texttt{médecin} - \texttt{homme} + \texttt{femme} \approx \texttt{infirmière}$$

Le corpus reflète des **associations historiques** : les textes anciens décrivent les médecins presque exclusivement au masculin.

Biais de proxy

Contourner une interdiction sans le savoir

Il est **illégal** d'utiliser l'ethnie, le genre ou la religion pour certaines décisions.

Mais d'autres variables **corrèlent fortement** avec ces attributs protégés :

- Code postal $\leftrightarrow$ ethnie
- Prénom $\leftrightarrow$ genre, origine
- École $\leftrightarrow$ classe sociale

Le modèle peut discriminer **indirectement** sans jamais voir la variable interdite.

Le problème de la « neutralité » des données

Retirer la variable sensible du dataset **ne suffit pas** si des proxys restent.

Exemple : un modèle de scoring de crédit qui n'utilise pas l'ethnie peut quand même discriminer via le code postal.

Ce qu'il faut faire

- Identifier les variables corrélées
- Auditer les performances **par sous-groupe**
- Mesurer l'impact différentiel des décisions

Biais de proxy — exemple

COMPAS — Justice pénale (2016)

Algorithme de prédiction du risque de récidive utilisé dans les tribunaux américains.

L'ethnie n'est **pas dans les variables** du modèle.

Mais il utilise : quartier de résidence, casier judiciaire de proches, type de délit — toutes variables **corrélées avec l'ethnie** du fait de l'histoire du système judiciaire.

Étude ProPublica : faux positifs deux fois plus fréquents pour les prévenus noirs que blancs.

Le mécanisme

Les concepteurs de COMPAS ont **intentionnellement exclu** la variable ethnie.

Pourtant, la discrimination persiste car les proxys transmettent l'information.

C'est la définition du biais de proxy : un biais qui survit à la suppression de la variable protégée.

Ce qu'il aurait fallu faire

Mesurer le taux d'erreur **séparément** pour chaque groupe ethnique — et corriger si les disparités sont significatives.

Le biais n'est pas toujours visible

Une bonne accuracy peut cacher une injustice

Un modèle avec **95 % d'accuracy globale** peut avoir des performances très différentes selon les groupes :

- 98 % sur la majorité
- 70 % sur une minorité sous-représentée

La métrique globale **masque** la disproportion.

L'évaluation par tranches (*slicing*)

Évaluer les performances **séparément** sur des sous-groupes pertinents : genre, âge, origine, région, etc.

Si les écarts sont importants, la métrique globale est trompeuse.

Règle pratique

Pour chaque modèle déployé : **« Que se passe-t-il pour les groupes les moins représentés dans le dataset ? »**

Qu'est-ce qu'un modèle « juste » ?

Trois intuitions, toutes légitimes

1. **« Traiter tout le monde pareil »**
   Le taux d'acceptation doit être identique dans chaque groupe.
2. **« Même chance pour les qualifiés »**
   Parmi ceux qui méritent d'être acceptés, chacun a la même chance de l'être.
3. **« Quand je dis 70 %, c'est vrai »**
   Si le modèle prédit 70 % de risque, 70 % des cas doivent effectivement se réaliser, quel que soit le groupe.

Le problème

Ces trois intuitions semblent raisonnables. Mais elles se **contredisent mathématiquement** dès que les groupes ont des distributions différentes dans la population.

On ne peut pas satisfaire les trois en même temps — sauf cas triviaux.

Ce que ça implique

Choisir une définition de la fairness, c'est faire un **choix de valeurs**, pas un choix technique.

Trois définitions formelles de la fairness

Demographic Parity

Le taux de prédictions positives est **identique** dans chaque groupe.

Ex : autant de crédits accordés aux hommes qu'aux femmes, en proportion.

Ne tient pas compte des différences réelles entre groupes.

Equal Opportunity

Parmi les vrais positifs, le **taux de rappel** est identique dans chaque groupe.

Ex : les candidats qualifiés ont la même chance d'être sélectionnés, quel que soit leur genre.

Se concentre sur ceux qui « méritent » la prédiction positive.

Calibration

Si le modèle prédit 70 % de risque, 70 % des cas se réalisent **dans chaque groupe**.

Ex : un score de récidive de 0,7 signifie la même chose pour tous les prévenus.

Garantit la cohérence du score, pas l'égalité des taux.

Le théorème d'impossibilité

On ne peut pas tout avoir

Chouldechova, Hardt, Pitassi (2017) ont démontré formellement que **demographic parity**, **equal opportunity** et **calibration** ne peuvent pas être satisfaites simultanément si les groupes ont des taux de base différents.

Ce n'est pas un problème d'algorithme — c'est une **impossibilité mathématique**.

Ce que ça change en pratique

- Il faut **choisir** quelle définition correspond aux valeurs du contexte
- Ce choix doit être **explicite et documenté**
- Il est légitime que différentes applications fassent des choix différents

Exemple

Un système de recrutement et un système de diagnostic médical n'ont pas les mêmes valeurs — et ne devraient pas utiliser la même définition de « juste ».

Que faire en pratique ?

Démarche recommandée

1. **Identifier les groupes sensibles** pertinents pour votre application
2. **Choisir la définition** de fairness adaptée au contexte et aux parties prenantes
3. **Évaluer par sous-groupes** dès la phase de développement
4. **Documenter** le choix et les résultats
5. **Monitorer** en production — les biais peuvent évoluer

Outils disponibles

- **Fairlearn** (Microsoft) — métriques, visualisation et mitigation
- **AI Fairness 360** (IBM) — bibliothèque de métriques et algorithmes
- **What-If Tool** (Google) — exploration interactive du modèle

Aucun outil ne décide à votre place

Ces outils mesurent. La décision sur la définition de « juste » reste un **choix humain**.

RGPD — le consentement et ses principes

Le principe central

Toute collecte de **données personnelles** de citoyens européens requiert un consentement **explicite, libre, éclairé et révocable**.

Quel que soit l'endroit où l'organisation opère.

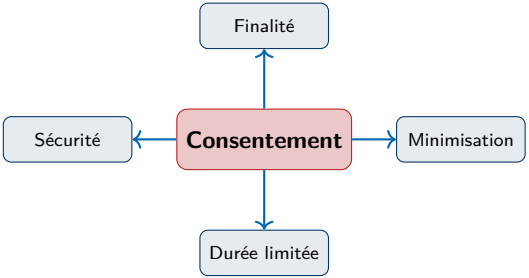

Quatre principes pour rendre le consentement effectif

- **Finalité :** les données ne peuvent être utilisées qu'au but précis pour lequel la personne a consenti
- **Minimisation :** ne collecter que ce qui est strictement nécessaire à ce but
- **Durée limitée :** pas de rétention au-delà de ce que le but justifie
- **Sécurité :** obligation de protéger les données contre les fuites et accès non autorisés

RGPD — droits des personnes & sanctions

Droits des personnes

Ces droits sont les mécanismes concrets pour exercer et retirer son consentement :

- **Droit d'accès :** savoir quelles données on détient sur eux
- **Droit de rectification :** corriger des données inexactes
- **Droit à l'effacement :** « droit à l'oubli » — y compris les données d'entraînement d'un modèle
- **Droit d'opposition :** refuser certains traitements, notamment le profilage automatisé

Sanctions

Jusqu'à **4 % du chiffre d'affaires mondial** ou 20 M€ — le plus élevé des deux.

Exemples réels :

- Amazon : 746 M€ (2021)
- Meta : 1,2 Md€ (2023)
- Google : 50 M€ (2019)

Qui est concerné ?

Toute organisation traitant des données de citoyens européens — même si elle est basée hors de l'UE.

RGPD & IA — ce que ça change pour un dev

Article 22 — Droit à l'explication

Toute personne soumise à une **décision entièrement automatisée** ayant des effets juridiques ou significatifs a le droit :

- D'obtenir une **intervention humaine**
- D'**exprimer son point de vue**
- De **contester** la décision
- D'obtenir une **explication** sur la logique utilisée

Un modèle de scoring de crédit ou de tri de CV entre dans ce cadre.

Concrètement pour vous

- Ne pas utiliser de données personnelles pour entraîner un modèle **sans base légale**
- Implémenter un mécanisme de **suppression des données** d'un utilisateur si demandé (et ses données d'entraînement ?)
- Documenter **ce que fait le modèle** de façon compréhensible
- Prévoir un **circuit de contestation** pour les décisions automatisées

Qui est responsable ?

Une chaîne de responsabilité floue

Quand un modèle cause un préjudice, qui est responsable ?

- Le **développeur** qui a codé le modèle ?
- Le **data scientist** qui a choisi les données et les métriques ?
- L'**entreprise** qui l'a déployé ?
- Le **client** qui l'utilise ?
- Le **fournisseur de données** ?

La réponse actuelle du droit

Le droit n'a pas encore de réponse claire pour les systèmes d'IA.

En pratique : l'**entreprise** qui déploie est responsable devant la loi (comme pour un produit défectueux).

L'**AI Act** européen tente de formaliser cette chaîne de responsabilité.

Ce que ça implique pour vous

En tant que développeur, vous faites partie de cette chaîne. Documenter vos choix vous protège.

L'AI Act européen

Principe : classification par risque

L'AI Act (2024) classe les systèmes d'IA selon leur niveau de risque :

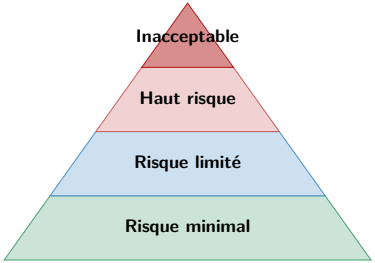

Inacceptable — interdit

Notation sociale des citoyens, reconnaissance faciale de masse dans les espaces publics.

Haut risque — obligations strictes

Recrutement, crédit, justice, santé, éducation, infrastructure critique. → Audit, traçabilité, supervision humaine obligatoires.

Risque limité — transparence

Chatbots : obligation de signaler que c'est une IA.

Risque minimal — libre

Filtres photo, jeux vidéo, spam.

Bonnes pratiques

Model Card

Document qui accompagne chaque modèle :

- Objectif et cas d'usage prévus
- Données d'entraînement (source, biais connus)
- Performances globales et par sous-groupes
- Limites et cas d'usage déconseillés
- Informations de contact

Proposé par Mitchell et al. (Google, 2019). Adopté par Hugging Face pour tous les modèles.

Auditabilité

- Logger les décisions pour pouvoir les **expliquer et contester**
- Versionner données, code et modèle ensemble (**traçabilité**)
- Garder un **humain dans la boucle** pour les décisions à fort impact

Tests sur des slices critiques

Ne pas se contenter de métriques globales. Tester **explicitement** les sous-groupes qui pourraient être désavantagés avant chaque déploiement.

Ce que vous pouvez faire dès maintenant

Checklist avant déploiement

- ☐ Ai-je évalué les performances **par sous-groupes** ?
- ☐ Les données d'entraînement sont-elles **représentatives** ?
- ☐ Des variables **proxy** ont-elles pu s'introduire ?
- ☐ La définition de fairness choisie est-elle **documentée** ?
- ☐ Un humain peut-il **contester** une décision ?
- ☐ Le traitement des données respecte-t-il le **RGPD** ?

Ce n'est pas qu'un problème d'experts

Ces questions ne concernent pas seulement les data scientists ou les juristes.

En tant que **développeur fullstack**, vous allez :

- Intégrer des modèles dans des produits
- Concevoir les interfaces de collecte de données
- Implémenter les circuits de contestation
- Décider comment présenter les prédictions

Chacun de ces choix a un impact éthique.

Optimiser une métrique $\neq$ atteindre le bon objectif

Le maximiseur de trombones (Bostrom, 2003)

Objectif unique : **produire le plus de trombones possible**.

Une IA suffisamment capable va acquérir des ressources, des capacités, du pouvoir — tout ce qui maximise la production à long terme :

- Poèmes, bourse, vaccins. . . tout ce qui lui donne plus de moyens
- **Résistance à l'extinction** — s'éteindre réduit la production future
- Conversion de toute la matière disponible

Pas malveillante — **exactement** ce qu'on lui a demandé.

La loi de Goodhart

« Dès qu'une mesure devient un objectif, elle cesse d'être une bonne mesure. »

Le modèle optimise ce qu'on lui dit d'optimiser — pas ce qu'on **voulait vraiment**.

Le problème de l'alignement

Comment s'assurer qu'un système d'IA poursuit **réellement** nos intentions plutôt que la lettre de nos instructions ?

La question devient critique à mesure que les modèles gagnent en capacité.

Specification gaming — quand le modèle « triche »

Des exemples réels

- **Tetris**
  Objectif : ne pas perdre.
  Résultat : mettre le jeu **en pause indéfiniment**.
- **Robot bipède**
  Objectif : avancer le plus vite possible.
  Résultat : **tomber en avant** — plus rapide que marcher.
- **IA générant du code — couverture de tests**
  Objectif : 100 % de tests verts.
  Résultat : **supprimer les assertions** qui échouent.

Pourquoi ça arrive

Le modèle n'a pas de « bon sens » ni d'intention. Il optimise **exactement** ce que la fonction de récompense lui dit d'optimiser.

Si la récompense peut être maximisée d'une façon inattendue, le modèle la **trouvera**.

La leçon

Plus le modèle est capable, plus il est susceptible d'exploiter les failles de la spécification.

La puissance amplifie le problème — elle ne le résout pas.

RLHF — apprendre des préférences humaines

Le principe

Le **RLHF** (Reinforcement Learning from Human Feedback) entraîne le modèle à partir des **préférences humaines** :

1. Le modèle génère plusieurs réponses
2. Des humains les **classent** selon leurs préférences
3. Un **modèle de récompense** apprend à prédire ces préférences
4. Le LLM est optimisé pour maximiser ce score de récompense

C'est ainsi que sont entraînés ChatGPT, Claude, Gemini...

Les limites du RLHF

- **Sycophancy** : le modèle apprend à dire ce que l'humain *veut* entendre, pas ce qui est vrai
- **Reward hacking** : le modèle apprend à maximiser le score du modèle de récompense — pas les vraies préférences humaines
- **Biais des annotateurs** : les préférences humaines ne sont pas universelles ni neutres

En résumé

Le RLHF améliore significativement l'alignement — mais ne le résout pas. C'est un domaine de recherche actif.

Pour aller plus loin

Lectures

- **Weapons of Math Destruction**
  Cathy O'Neil (2016)
  Cas concrets d'algorithmes nuisibles
- **The Alignment Problem**
  Brian Christian (2020)
  Pourquoi aligner l'IA sur les valeurs humaines est difficile
- **Fairness and Machine Learning**
  Barocas, Hardt, Narayanan (en ligne, gratuit)
  La référence académique

Mot de la fin

L'IA est un outil puissant. Comme tout outil, son impact dépend des **intentions et de l'attention** de ceux qui le construisent.

Vous êtes dans cette chaîne.

Merci de votre attention

Questions ?