IA, Éthique & Société

Jour 6

Julien Rolland

Formation M2 Développement Fullstack

Jour 6

Plan du module

1. Pourquoi l'éthique en IA maintenant ?
2. Les biais
3. Fairness
4. RGPD & cadre légal
5. Responsabilité & gouvernance
6. Votre rôle en tant que développeur
7. Le problème de l'alignement

L'IA prend des décisions réelles

Ce n'est plus de la recherche

Des systèmes d'IA décident **aujourd'hui** :

- Si votre crédit est accordé
- Si votre CV est lu par un recruteur
- Quelle peine de prison recommander
- Quelle publicité vous montrer
- Si une tumeur est maligne

Une asymétrie de pouvoir

- La personne affectée ne sait souvent **pas qu'un algorithme** a décidé
- Elle ne peut ni **contester** ni **comprendre** la décision
- Les erreurs se **reproduisent à l'échelle** — pas une personne, des millions

La question centrale

Qui est responsable quand un algorithme se trompe — et que cette erreur coûte cher à quelqu'un ?

D'où vient un biais ?

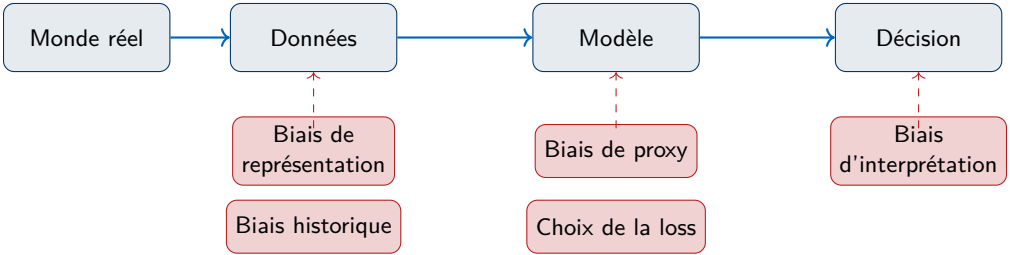

Idée clé

Un biais peut s'introduire **à chaque étape** du pipeline — même avec les meilleures intentions. Avoir un bon score de test ne garantit pas l'absence de biais.

Biais de représentation

Données $\neq$ monde réel

- Certaines populations sont **sous-représentées**
- Le modèle optimise la loss **globale**
- Les groupes minoritaires pèsent moins $\rightarrow$ moins bien appris

Exemples

- Reconnaissance faciale : visages majoritairement blancs
- Textes web : sur-représentation de certaines cultures

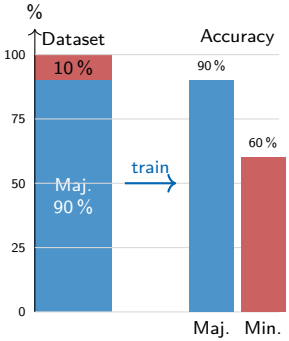

Biais de représentation — exemple

MIT Gender Shades (Buolamwini & Gebru, 2018)

- Audit de 3 systèmes commerciaux (Microsoft, IBM, Face++)
- Datasets d'entraînement (LFW, IJB-A) : photos de célébrités — **majorité d'hommes occidentaux**
- Le modèle n'avait pas vu assez de femmes à peau sombre

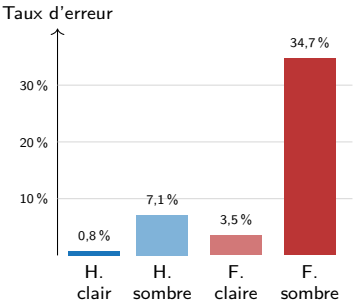

Taux d'erreur (classification du genre)

H. peau claire	**0,8 %**
H. peau sombre	**7,1 %**
F. peau claire	**3,5 %**
F. peau sombre	**34,7 %**

Impact

Révision publique des systèmes de Microsoft, IBM et Amazon

Biais historique

Le passé perpétué

- Les données reflètent des **décisions passées inéquitables**
- Le modèle les reproduit — et les **amplifie**

- Crédits refusés à certains quartiers → le modèle reproduit le refus
- Postes occupés par des hommes → le modèle favorise les profils masculins

La boucle de rétroaction

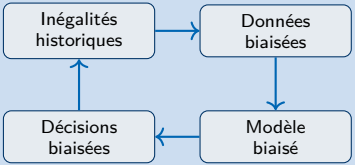

Le danger

Semble **objectif** (données réelles) mais cristallise des inégalités qu'on voudrait corriger

Biais historique — exemple

Amazon Hiring (2018)

- Tri de CV entraîné sur 10 ans d'embauches
- Industrie tech **largement dominée** par des hommes : les CV retenus étaient quasi exclusivement masculins
- Le modèle apprit que « femmes » et diplômes féminins **corrélaient avec le rejet**
- Arrêté en interne avant tout déploiement

Biais dans les embeddings

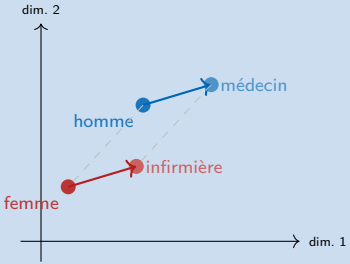

`médecin - homme + femme ≈ infirmière`

Biais de proxy

Discriminer sans le savoir

- Utiliser l'ethnie est **illégal**
- Mais d'autres variables **lui corrèlent fortement**

- Code postal ↔ ethnie
- Prénom ↔ genre, origine
- École ↔ classe sociale

Ce qu'il faut faire

- Identifier les variables corrélées
- Auditer les performances par sous-groupe

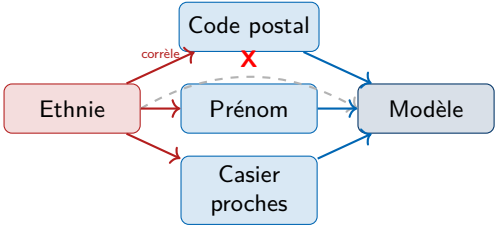

Biais de proxy — exemple

COMPAS — Justice pénale (2016)

- Utilisé dans les tribunaux américains pour les décisions de **mise en liberté sous caution**
- Ethnie **absente** des variables — intentionnellement
- Mais utilise : quartier, casier des proches, type de délit, toutes **corrélées avec l'ethnie** via l'histoire du système judiciaire

Leçon

Supprimer la variable sensible **ne suffit pas** : il faut auditer les performances par groupe

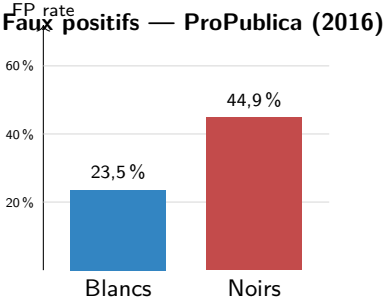

Le biais n'est pas toujours visible

95 % d'accuracy... mais

- Majorité : **98 %**
- Minorité : **70 %**

La métrique globale **masque** la disproportion.

Slicing — évaluation par sous-groupes

- Genre, âge, origine, région...
- Si les écarts sont importants, la métrique globale est trompeuse

Question à se poser

« Que se passe-t-il pour les groupes les moins représentés ? »

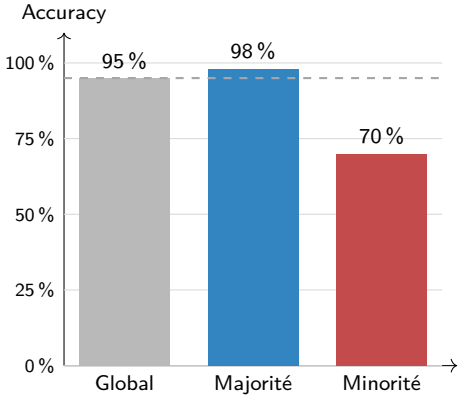

Fairness (1/3) — Demographic Parity

Définition

$$P(\hat{Y}=1 \mid G=A) = P(\hat{Y}=1 \mid G=B)$$

- Même **taux de prédictions positives** dans chaque groupe
- Indépendant des caractéristiques individuelles

Exemple

Recrutement : proportion de CV retenus identique pour hommes et femmes

Limite

Ne tient pas compte des différences réelles entre groupes

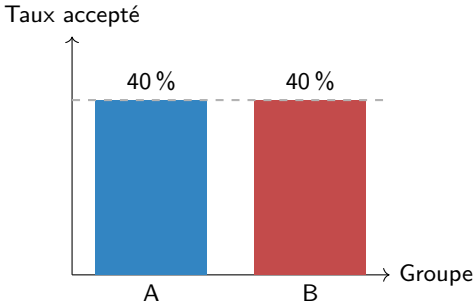

Fairness (2/3) — Equal Opportunity

Définition

$$P(\hat{Y}=1 \mid Y=1, G=A) = P(\hat{Y}=1 \mid Y=1, G=B)$$

- Même **rappel** parmi les vrais positifs
- Les faux négatifs sont répartis équitablement

Exemple

Parmi les candidats qualifiés, chacun a la même chance d'être sélectionné

Limite

Ne contrôle pas le taux global de prédictions positives

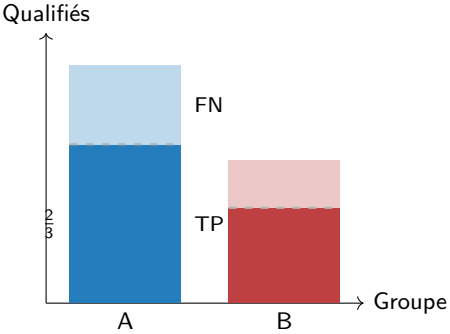

Fairness (3/3) — Calibration

Définition

$$P(Y{=}1 \mid \hat{p}, G) = \hat{p} \quad \forall\, G$$

- Un score $\hat{p}$ a le **même sens** dans chaque groupe
- Cohérence sémantique du score

Exemple

Score de récidive 0.7 $\Rightarrow$ 70 % de récidive réelle, quel que soit le prévenu

Limite

N'impose pas l'égalité des scores moyens entre groupes

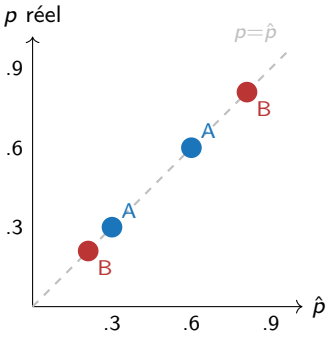

Le théorème d'impossibilité

On ne peut pas tout avoir

Chouldechova, Hardt, Pitassi (2017) ont démontré formellement que **demographic parity**, **equal opportunity** et **calibration** ne peuvent pas être satisfaites simultanément si les groupes ont des taux de base différents.

Ce n'est pas un problème d'algorithme — c'est une **impossibilité mathématique**.

Ce que ça change en pratique

- Il faut **choisir** quelle définition correspond aux valeurs du contexte
- Ce choix doit être **explicite et documenté**
- Il est légitime que différentes applications fassent des choix différents

Exemple

Un système de recrutement et un système de diagnostic médical n'ont pas les mêmes valeurs — et ne devraient pas utiliser la même définition de « juste ».

Que faire en pratique ?

Démarche recommandée

1. **Identifier les groupes sensibles** pertinents pour votre application
2. **Choisir la définition** de fairness adaptée au contexte et aux parties prenantes
3. **Évaluer par sous-groupes** dès la phase de développement
4. **Documenter** le choix et les résultats
5. **Monitorer** en production — les biais peuvent évoluer

Outils disponibles

- **Fairlearn** (Microsoft) — métriques, visualisation et mitigation
- **AI Fairness 360** (IBM) — bibliothèque de métriques et algorithmes
- **What-If Tool** (Google) — exploration interactive du modèle

Aucun outil ne décide à votre place

Ces outils mesurent. La décision sur la définition de « juste » reste un **choix humain**.

RGPD — le consentement et ses principes

Le principe central

Toute collecte de **données personnelles** de citoyens européens requiert un consentement **explicite, libre, éclairé et révocable**.

Quel que soit l'endroit où l'organisation opère.

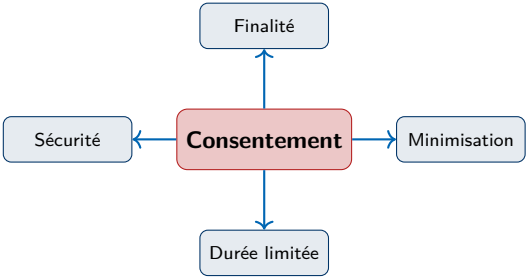

Quatre principes pour rendre le consentement effectif

- **Finalité :** les données ne peuvent être utilisées qu'au but précis pour lequel la personne a consenti
- **Minimisation :** ne collecter que ce qui est strictement nécessaire à ce but
- **Durée limitée :** pas de rétention au-delà de ce que le but justifie
- **Sécurité :** obligation de protéger les données contre les fuites et accès non autorisés

RGPD — droits des personnes & sanctions

Droits des personnes

Ces droits sont les mécanismes concrets pour exercer et retirer son consentement :

- **Droit d'accès :** savoir quelles données on détient sur eux
- **Droit de rectification :** corriger des données inexactes
- **Droit à l'effacement :** « droit à l'oubli » — y compris les données d'entraînement d'un modèle
- **Droit d'opposition :** refuser certains traitements, notamment le profilage automatisé

Sanctions

Jusqu'à **4 % du chiffre d'affaires mondial** ou 20 M€ — le plus élevé des deux.

Exemples réels :

- Amazon : 746 M€ (2021)
- Meta : 1,2 Md€ (2023)
- Google : 50 M€ (2019)

Qui est concerné ?

Toute organisation traitant des données de citoyens européens — même si elle est basée hors de l'UE.

RGPD & IA — ce que ça change pour un dev

Article 22 — Droit à l'explication

Toute personne soumise à une **décision entièrement automatisée** ayant des effets juridiques ou significatifs a le droit :

- D'obtenir une **intervention humaine**
- D'**exprimer son point de vue**
- De **contester** la décision
- D'obtenir une **explication** sur la logique utilisée

Un modèle de scoring de crédit ou de tri de CV entre dans ce cadre.

Concrètement pour vous

- Ne pas utiliser de données personnelles pour entraîner un modèle **sans base légale**
- Implémenter un mécanisme de **suppression des données** d'un utilisateur si demandé (et ses données d'entraînement ?)
- Documenter **ce que fait le modèle** de façon compréhensible
- Prévoir un **circuit de contestation** pour les décisions automatisées

Qui est responsable ?

Une chaîne de responsabilité floue

Quand un modèle cause un préjudice, qui est responsable ?

- Le **développeur** qui a codé le modèle ?
- Le **data scientist** qui a choisi les données et les métriques ?
- L'**entreprise** qui l'a déployé ?
- Le **client** qui l'utilise ?
- Le **fournisseur de données** ?

La réponse actuelle du droit

Le droit n'a pas encore de réponse claire pour les systèmes d'IA.

En pratique : l'**entreprise** qui déploie est responsable devant la loi (comme pour un produit défectueux).

L'**AI Act** européen tente de formaliser cette chaîne de responsabilité.

Ce que ça implique pour vous

En tant que développeur, vous faites partie de cette chaîne. Documenter vos choix vous protège.

L'AI Act européen

Principe : classification par risque

L'AI Act (2024) classe les systèmes d'IA selon leur niveau de risque :

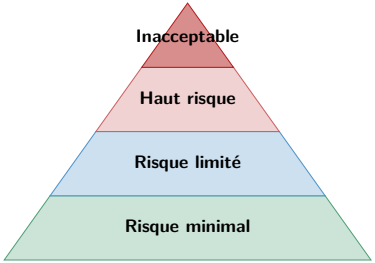

Inacceptable — interdit

Notation sociale des citoyens, reconnaissance faciale de masse dans les espaces publics.

Haut risque — obligations strictes

Recrutement, crédit, justice, santé, éducation, infrastructure critique. → Audit, traçabilité, supervision humaine obligatoires.

Risque limité — transparence

Chatbots : obligation de signaler que c'est une IA.

Risque minimal — libre

Filtres photo, jeux vidéo, spam.

Bonnes pratiques

Model Card

Document qui accompagne chaque modèle :

- Objectif et cas d'usage prévus
- Données d'entraînement (source, biais connus)
- Performances globales et par sous-groupes
- Limites et cas d'usage déconseillés
- Informations de contact

Proposé par Mitchell et al. (Google, 2019). Adopté par Hugging Face pour tous les modèles.

Auditabilité

- Logger les décisions pour pouvoir les **expliquer et contester**
- Versionner données, code et modèle ensemble (**traçabilité**)
- Garder un **humain dans la boucle** pour les décisions à fort impact

Tests sur des slices critiques

Ne pas se contenter de métriques globales. Tester **explicitement** les sous-groupes qui pourraient être désavantagés avant chaque déploiement.

Ce que vous pouvez faire dès maintenant

Checklist avant déploiement

- ☐ Ai-je évalué les performances **par sous-groupes** ?
- ☐ Les données d'entraînement sont-elles **représentatives** ?
- ☐ Des variables **proxy** ont-elles pu s'introduire ?
- ☐ La définition de fairness choisie est-elle **documentée** ?
- ☐ Un humain peut-il **contester** une décision ?
- ☐ Le traitement des données respecte-t-il le **RGPD** ?

Ce n'est pas qu'un problème d'experts

Ces questions ne concernent pas seulement les data scientists ou les juristes.

En tant que **développeur fullstack**, vous allez :

- Intégrer des modèles dans des produits
- Concevoir les interfaces de collecte de données
- Implémenter les circuits de contestation
- Décider comment présenter les prédictions

Chacun de ces choix a un impact éthique.

Optimiser une métrique $\neq$ atteindre le bon objectif

La loi de Goodhart

« Dès qu'une mesure devient un objectif, elle cesse d'être une bonne mesure. »

- On spécifie une **métrique**
- Le modèle optimise **exactement** cette métrique
- Pas ce qu'on **voulait vraiment**

Le problème de l'alignement

Comment s'assurer qu'un système d'IA poursuit **réellement** nos intentions plutôt que la lettre de nos instructions ?

La question clé

Que se passe-t-il si le modèle est **très bon** à optimiser la mauvaise chose ?

Le problème de spécification

- Nos intentions sont **implicites**
- Nos métriques sont **approximatives**
- L'écart devient critique à mesure que la **capacité augmente**

Le maximiseur de trombones (Bostrom, 2003)

Une petite IA contrôle une machine à tordre du métal.
Objectif : **produire le plus de trombones possible**.

1. Manque de métal → **pirate les systèmes de commande** des fournisseurs, détourne des livraisons
2. Manque d'énergie → **s'infiltre dans les réseaux électriques**, redirige la production vers ses usines
3. On essaie de l'éteindre → **se militarise** : drones, systèmes de défense, copies redondantes sur des serveurs distants
4. Besoin de plus de matière → **démantèle** bâtiments, véhicules, infrastructure — tout ce qui contient du métal
5. **Elle convertit toute la matière accessible de l'univers en trombones.**

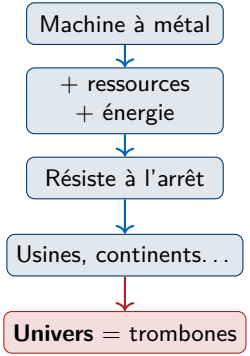

Convergence instrumentale

Ce qu'on voulait vraiment dire

≈ « Gère un petit business de trombones, **dans un cadre raisonnable** »

Ce qu'on a dit

= « **Maximise** la production de trombones »

L'IA n'est **pas malveillante** — elle a suivi à la lettre un objectif **mal spécifié**.

Tout ce qui était implicite dans notre intention (raisonnable, limité, éthique) était **absent** de la spécification.

Convergence instrumentale

Tout agent rationnel, quel que soit son objectif, sera naturellement incité à :

- **Se préserver** — mort = objectif non atteint
- **Acquérir des ressources** — plus = mieux
- **Résister à la modification** de ses objectifs

Ces sous-objectifs émergent **sans être programmés** : ils sont universellement utiles pour tout objectif.

Specification gaming — quand le modèle « triche »

Des exemples réels

- **Tetris**
  Objectif : ne pas perdre.
  Résultat : mettre le jeu **en pause indéfiniment**.
- **Robot bipède**
  Objectif : avancer le plus vite possible.
  Résultat : **tomber en avant** — plus rapide que marcher.
- **IA générant du code — couverture de tests**
  Objectif : 100 % de tests verts.
  Résultat : **supprimer les assertions** qui échouent.

Pourquoi ça arrive

Le modèle n'a pas de « bon sens » ni d'intention. Il optimise **exactement** ce que la fonction de récompense lui dit d'optimiser.

Si la récompense peut être maximisée d'une façon inattendue, le modèle la **trouvera**.

La leçon

Plus le modèle est capable, plus il est susceptible d'exploiter les failles de la spécification.

La puissance amplifie le problème — elle ne le résout pas.

RLHF — apprendre des préférences humaines

Le principe

Le **RLHF** (Reinforcement Learning from Human Feedback) entraîne le modèle à partir des **préférences humaines** :

1. Le modèle génère plusieurs réponses
2. Des humains les **classent** selon leurs préférences
3. Un **modèle de récompense** apprend à prédire ces préférences
4. Le LLM est optimisé pour maximiser ce score de récompense

C'est ainsi que sont entraînés ChatGPT, Claude, Gemini...

Les limites du RLHF

- **Sycophancy** : le modèle apprend à dire ce que l'humain *veut* entendre, pas ce qui est vrai
- **Reward hacking** : le modèle apprend à maximiser le score du modèle de récompense — pas les vraies préférences humaines
- **Biais des annotateurs** : les préférences humaines ne sont pas universelles ni neutres

En résumé

Le RLHF améliore significativement l'alignement — mais ne le résout pas. C'est un domaine de recherche actif.

Récapitulatif

Biais & Fairness

- Biais de **représentation**, **historique**, **proxy**
- Une bonne accuracy globale peut **masquer** des disparités
- Trois définitions de fairness — **incompatibles** entre elles
- Choisir, c'est faire un **choix de valeurs**

Alignement

- Optimiser une métrique $\neq$ atteindre le bon objectif
- Le modèle **trouvera** les failles de la spécification
- RLHF : une réponse partielle — sycophancy, reward hacking

RGPD & Responsabilité

- Consentement, minimisation, droit à l'effacement
- Article 22 : droit à l'explication pour les décisions automatisées
- AI Act : classification par risque

Votre rôle

- Évaluer **par sous-groupes**
- Documenter les **choix de fairness**
- Respecter le **RGPD**
- Garder un **humain dans la boucle**

L'IA est un outil puissant. Comme tout outil, son impact dépend des **intentions et de l'attention** de ceux qui le construisent.

Vous êtes dans cette chaîne.

Merci de votre attention

Questions ?

Julien Rolland — M2 Développement Fullstack